

Emotionserkennung in Video-Calls mit Künstlicher Intelligenz

MARVIN KOCH 2510781009@hochschule-burgenland.at and NIKOLA RADULOVIĆ 2510781016@hochschule-burgenland.at

KURZFASSUNG: Mit der zunehmenden Nutzung digitaler Kommunikationsformate gewannen auch Videogespräche im beruflichen und privaten Austausch an Bedeutung. Gleichzeitig wurde deutlich, dass in virtuellen Interaktionen nonverbale und emotionale Signale häufig nur eingeschränkt wahrgenommen wurden. Dieses Position Paper war im Forschungsfeld der Künstlichen Intelligenz (KI), des Affective Computing sowie der Human-Computer-Interaction angesiedelt und befasste sich mit der automatischen Emotionserkennung in digitalen Videogesprächen. Ausgangspunkt war die Beobachtung, dass nonverbale Signale in Video-Calls oft nur eingeschränkt wahrgenommen wurden, obwohl sie für das Verständnis von Reaktionen, Interesse oder Ablehnung eine wichtige Rolle spielten.

Es wurde die Problemstellung betrachtet, dass Gesprächsführende in digitalen Kommunikationssituationen emotionale Reaktionen ihres Gegenübers häufig nicht zuverlässig erkennen konnten. Dadurch entstanden potenzielle Missverständnisse und es wurde erschwert, das eigene Kommunikationsverhalten situationsgerecht anzupassen. Besonders in Präsentations- oder Gesprächssituationen mit aktivierter Kamera stellte dies eine relevante Herausforderung dar.

Zur Bearbeitung dieser Problemstellung wurde ein prototypischer Ansatz vorgeschlagen, der Gesichtsausdrücke eines Gesprächspartners in einem One-to-One-Video-Call in Echtzeit analysierte und die erkannte Stimmung über eine Webapplikation zurückmeldete. Methodisch wurde dazu ein Use Case formuliert, ein technischer Systemaufbau mit Webanwendung und Cloud-Verarbeitung beschrieben sowie ein Evaluationskonzept für die Untersuchung des Nutzens entworfen.

Es wurde erwartet, dass ein solcher Ansatz dabei half, emotionale Reaktionen im Gespräch bewusster wahrzunehmen und dadurch die Gesprächsführung gezielter anzupassen. Der vorgeschlagene Lösungsansatz sollte somit einen Beitrag dazu leisten, digitale Kommunikation verständlicher und reaktionsfähiger zu gestalten. Im weiteren Verlauf der Arbeit sollten die technische Umsetzung, die experimentelle Evaluation und die Analyse der praktischen Grenzen des Systems ausgearbeitet werden.

1 Einleitung und Problemhintergrund

Digitale Kommunikation spielt eine zentrale Rolle im beruflichen und privaten Alltag, wobei Videokonferenzen die Zusammenarbeit über große Distanzen hinweg ermöglichen. Plattformen wie Zoom oder Microsoft Teams sind daher wichtige Werkzeuge moderner Kommunikation [2]. Gleichzeitig verändert diese Form der Kommunikation jedoch auch die Art und Weise, wie Menschen miteinander interagieren [3]. In persönlichen Gesprächen werden emotionale Reaktionen häufig über nonverbale Signale wahrgenommen, wobei insbesondere Gesichtsausdrücke wichtige Hinweise auf die Stimmung eines Gesprächspartners liefern. Im Forschungsfeld der Künstlichen Intelligenz (KI) wird daher untersucht, wie solche emotionalen Informationen automatisch erkannt werden können. Ein zentraler Ansatz dabei ist die Analyse von Gesichtsausdrücken durch Systeme der Emotionserkennung.

Trotz moderner Videokonferenzsysteme bleibt das Verständnis emotionaler Reaktionen oft eingeschränkt, da Teilnehmer nicht immer erkennen, wie ihr Gesprächspartner auf Inhalte reagiert. Dies kann zu Missverständnissen oder einer weniger effektiven Kommunikation führen. Gerade in Situationen wie Präsentationen oder Verhandlungen spielen emotionale Reaktionen eine wichtige Rolle, da sie helfen können, die eigene Kommunikation anzupassen. Wenn diese jedoch nicht erkannt werden, fällt es Gesprächsführenden schwer, entsprechend zu reagieren. Zusätzlich erschweren digitale Meetings die Interpretation emotionaler Signale, da die Mimik eines Gesprächspartners oft nicht bewusst wahrgenommen wird.

Im Rahmen dieser Projektarbeit soll daher ein prototypisches System entwickelt werden, das Emotionen während eines Videomeetings automatisch erkennt und bewertet. Die Analyse basiert auf der Auswertung von Gesichtsausdrücken mithilfe von KI. Das System soll während eines Meetings in Echtzeit arbeiten und die aktuelle Stimmung des Gesprächs in einer Webapplikation bereitstellen. Voraussetzung dafür ist lediglich der Zugriff auf das Videobild des Gesprächspartners. Die erkannten Emotionen werden dem Nutzer anschließend in Form kurzer visueller Hinweise dargestellt, beispielsweise über eine Smiley-Skala oder Emojis zur Einordnung der aktuellen Stimmung. Ziel ist es, zu untersuchen, ob solche Informationen dabei helfen können, Gespräche bewusster zu steuern. Zur Evaluierung des Prototyps wird folgender Use Case definiert: Eine Person führt im Rahmen eines One-to-One-Video-Calls ein Gespräch mit einer anderen Person, während beide Teilnehmer ihre Kameras aktiviert haben. Das System analysiert kontinuierlich die Gesichtsausdrücke des Gesprächspartners und überführt diese in eine Bewertungsskala, die dessen aktuelle Stimmung widerspiegelt. Diese Skala setzt sich dabei aus diskreten Emotionsklassen wie beispielsweise positiv, neutral und negativ zusammen, die zusätzlich durch eine Gewichtung der erkannten Gesichtsausdrücke (z. B. Freude, Neutralität oder Ärger) bestimmt werden. Dadurch erhält der Nutzer in Echtzeit Rückmeldung darüber, wie die Inhalte aufgenommen werden, beispielsweise ob Interesse, Zustimmung oder eher negative Reaktionen überwiegen. Auf Basis dieses Use Cases kann bewertet werden, ob das System in der Lage ist, sinnvolle und verständliche Rückmeldungen zu liefern und ob diese dem Nutzer dabei helfen, das Gespräch dynamisch anzupassen.

2 Stand des Wissens

Die automatische Erkennung von Emotionen anhand von Gesichtsausdrücken ist ein etabliertes Forschungsfeld innerhalb von Computer Vision, Affective Computing und Human-Computer-Interaction. In der Literatur wird dieses Gebiet meist als *Facial Expression Recognition* (FER) bezeichnet. Grundsätzlich lassen sich bestehende Ansätze in klassische, merkmalsbasierte Verfahren und moderne Deep-Learning-basierte Methoden unterteilen. Während klassische Verfahren einer Pipeline aus Gesichtserkennung, Merkmalsextraktion und Klassifikation folgen, nutzen neuere Arbeiten vor allem Convolutional Neural Networks, um Merkmale direkt aus Bilddaten zu lernen [4, 7, 11, 12].

Aktuelle Übersichtsarbeiten zeigen, dass sich die Forschung zu FER besonders auf Datensätze, Modellarchitekturen, Robustheit und Echtzeitfähigkeit konzentriert. Shehu et al. betonen, dass viele Deep-Learning-Modelle zwar hohe Genauigkeiten auf Benchmarks erreichen, jedoch empfindlich auf irrelevante Bildveränderungen reagieren. Sajjad et al. heben hervor, dass insbesondere echtzeitfähige und ressourcenschonende Systeme für praktische Anwendungen an Bedeutung gewinnen [12, 13].

Ein wichtiges Fundament vieler Arbeiten ist das *Facial Action Coding System* (FACS), das Gesichtsausdrücke anhand sogenannter *Action Units* beschreibt. Dadurch lassen sich mimische Veränderungen systematisch erfassen. Da die manuelle FACS-Codierung jedoch sehr aufwendig ist, wird die automatische Erkennung von Action Units zunehmend in moderne FER-Systeme integriert [7, 14].

Auch öffentliche Datensätze wie JAFFE, CK+, FER2013, RAF-DB und AffectNet sind zentral für die Entwicklung und Bewertung von FER-Systemen. Sie verbessern die Vergleichbarkeit von Ansätzen, bilden reale Kommunikationssituationen jedoch nur eingeschränkt ab, da viele Aufnahmen unter kontrollierten Bedingungen oder mit gestellten Emotionen entstanden sind. Gute Benchmark-Ergebnisse lassen sich daher nicht ohne Weiteres auf spontane Mimik in realen Anwendungen übertragen [5, 10, 13].

Ein weiterer Schwerpunkt liegt auf der Robustheit unter realen Bedingungen, etwa bei wechselnder Beleuchtung, Kopfbewegungen, unterschiedlichen Perspektiven, Okklusionen oder geringer Bildqualität. Koujan et al. zeigen mit einem echtzeitfähigen Ansatz zur Emotionserkennung "in the wild", dass robuste Erkennung grundsätzlich möglich ist, wenn 3D-Expressionsinformationen von Identitätsmerkmalen getrennt werden [9]. Darüber hinaus werden neben diskreten Basisemotionen zunehmend auch kontinuierliche Emotionsmodelle untersucht. Tan et al. schlagen hierzu einen kontinuierlichen "Emotion Index" auf Basis vorhergesagter Action Units vor, um emotionale Zustände differenzierter abzubilden [8, 14].

Zusammenfassend zeigt der Stand des Wissens deutliche Fortschritte bei Datensätzen, Modellarchitekturen und Echtzeitverfahren. Gleichzeitig konzentrieren sich viele Arbeiten vor allem auf Modellleistung, Benchmark-Vergleiche oder technische Robustheit. Weniger untersucht ist hingegen, wie solche Ansätze in einem konkreten Videomeeting-Kontext eingesetzt werden können, um einer sprechenden Person in Echtzeit verständliche Rückmeldungen zur Stimmung eines Gesprächspartners zu geben. Genau an dieser Stelle setzt die vorliegende Arbeit an und überführt bestehende FER-Ansätze in ein konkretes One-to-One-Video-Call-Szenario [6, 12, 13].

3 Methodischer Ansatz

Dieses Kapitel beschreibt den methodischen Ansatz der Arbeit und erläutert die Vorgehensweise sowie die eingesetzten Methoden zur Bearbeitung der Forschungsfrage. Dabei werden zunächst der zugrunde liegende Use Case sowie der Aufbau des entwickelten Systems vorgestellt. Anschließend werden die technischen Komponenten und der Evaluationsansatz näher erläutert.

3.1 Use-Case Definition

Als Ausgangspunkt für den methodischen Ansatz wird ein klar abgegrenzter Anwendungsfall definiert, der im Rahmen der Evaluation reproduzierbar umgesetzt werden kann. Der Use Case orientiert sich an einer vereinfachten Präsentationssituation innerhalb eines Videomeetings. Im konkreten Versuchsaufbau besteht das Meeting aus genau zwei Personen: einer präsentierenden Person und genau einem Teilnehmer mit aktivierter Kamera. Diese Reduktion ermöglicht es, die Funktionsweise des Systems unter kontrollierten Bedingungen zu untersuchen und die Ergebnisse eindeutig zuzuordnen. Während der Präsentation wird kontinuierlich das Videobild des Teilnehmers analysiert. Ziel ist es, dessen emotionale Reaktionen in Echtzeit zu erfassen und daraus eine laufende Einschätzung der aktuellen Stimmung abzuleiten. Diese Einschätzung wird der präsentierenden Person während des Vortrags direkt angezeigt. Im Gegensatz zu komplexeren Szenarien mit mehreren Teilnehmern liegt der Fokus hier bewusst auf der Interaktion zwischen zwei Personen. Dadurch kann präzise beobachtet werden, wie sich erkannte Emotionen auf die Wahrnehmung und das Verhalten der präsentierenden Person auswirken.

Der Use Case definiert somit klar, was untersucht wird: die automatische Erkennung und Rückmeldung von Emotionen in einer kontrollierten Präsentationssituation mit genau einem Zuhörer.

Das folgende Diagramm veranschaulicht die Beschreibung des Uses-Cases.




Fig. 1. Use-Case Veranschaulichung

3.2 Technische Beschreibung des Prototyps

Zur Umsetzung des Use Cases wird ein prototypisches System entwickelt, das Emotionen aus Videodaten erkennt und in Echtzeit verarbeitet. Der Prototyp ist als Webanwendung umgesetzt, wobei die Verarbeitung zentral über eine Cloud-Infrastruktur erfolgt.

3.2.1 Systemaufbau. Das System besteht aus einer Client-Komponente (Webanwendung) und einer serverseitigen Verarbeitung in der Cloud. Die Webanwendung wird von der präsentierenden Person genutzt und stellt die Benutzeroberfläche sowie den Zugriff auf den Videostream bereit. Der Videostream des Teilnehmers wird in regelmäßigen Abständen in Einzelbilder zerlegt und an eine serverseitige Komponente übermittelt. Diese Komponente ist in der Cloud-Infrastruktur von Amazon Web Services implementiert.

Innerhalb dieser Infrastruktur erfolgt die gesamte weitere Verarbeitung. Dazu zählen die Gesichtserkennung, die

Klassifikation der Emotionen sowie die Auswertung der Ergebnisse. Die Resultate werden anschließend an die Webanwendung zurückgesendet und dort visualisiert.

3.2.2 Verarbeitungsschritte. Der Ablauf der Verarbeitung ist klar strukturiert und reproduzierbar definiert:

Zunächst wird der Videostream des Teilnehmers in festen Zeitintervallen in Frames zerlegt. Diese Frames werden direkt an die serverseitige Verarbeitung übermittelt. Auf der Serverseite wird für jedes eingehende Bild eine Gesichtserkennung durchgeführt. Das erkannte Gesicht wird anschließend isoliert und an ein Modell zur Emotionserkennung übergeben.

Das Modell klassifiziert den Gesichtsausdruck in eine der definierten Kategorien (Freude, Neutralität, Überraschung, Traurigkeit, Ärger). Da im Versuchsaufbau nur ein Teilnehmer vorhanden ist, entspricht die erkannte Emotion direkt der aktuellen Gesamtstimmung. Die erkannten Emotionen werden über die Zeit hinweg gespeichert, sodass ein Verlauf der emotionalen Reaktionen entsteht. Dieser Verlauf bildet die Grundlage für die spätere Analyse. Die Ergebnisse werden unmittelbar nach der Verarbeitung an den Client zurückgesendet und dort in Echtzeit dargestellt.

3.2.3 Technische Umsetzung. Die serverseitige Verarbeitung wird vollständig innerhalb von Amazon Web Services umgesetzt.

Für die Entgegennahme der Bilddaten wird eine API bereitgestellt. Die Verarbeitung der Bilder erfolgt über eine serverlose Architektur, bei der eingehende Requests automatisch verarbeitet werden. Die Emotionserkennung wird innerhalb dieser Umgebung durch ein integriertes Modell durchgeführt.

Die Zwischenergebnisse sowie der zeitliche Verlauf der Emotionen werden in einer Cloud-Datenbank gespeichert. Dadurch ist sichergestellt, dass alle relevanten Daten für die spätere Evaluation verfügbar sind. Die Entscheidung für diese Architektur ermöglicht eine klare Trennung zwischen Frontend und Verarbeitung sowie eine reproduzierbare und skalierbare Umsetzung des Versuchsaufbaus.

Das folgende Diagramm zeigt die AWS-Architektur [1] des Systems.




Fig. 2. Architekturdiagramm

3.3 Evaluations- und Analyseansatz

Zur Bewertung des Prototyps wird eine strukturierte Evaluation durchgeführt, die direkt auf dem definierten Use Case basiert.

3.3.1 Versuchsaufbau. Die Evaluation erfolgt in einer kontrollierten Umgebung mit zwei Personen: einer präsentierenden Person und einem Teilnehmer.

Es werden zwei Durchläufe durchgeführt. Im ersten Durchlauf präsentiert die Person ohne Unterstützung durch das System. Im zweiten Durchlauf wird das System aktiviert und liefert während der Präsentation kontinuierlich Rückmeldungen zur erkannten Emotion des Teilnehmers. Durch diese Gegenüberstellung kann der Einfluss des Systems direkt beobachtet werden.

3.3.2 Datenerhebung. Die Datenerhebung erfolgt im Rahmen eines kontrollierten Experiments. Dabei durchläuft die präsentierende Person zwei Versuchsbedingungen: einen Durchlauf ohne Unterstützung durch das System sowie einen zweiten Durchlauf mit aktivierter Emotionserkennung.

Während beider Durchläufe werden kontinuierlich die vom System erkannten Emotionen aufgezeichnet und gespeichert. Ergänzend werden nach jedem Durchlauf standardisierte Befragungen durchgeführt, um subjektive Einschätzungen der Beteiligten zu erfassen.

Durch dieses Vorgehen wird sowohl eine quantitative Datenerhebung (Emotionserkennung und Verlauf) als auch eine qualitative Datenerhebung (subjektive Bewertung) ermöglicht.

3.3.3 *Evaluationsmetriken.* Die Bewertung des Systems erfolgt anhand von drei zentralen Metriken:

- *M1 - Genauigkeit der Emotionserkennung:* Vergleich zwischen den erkannten Emotionen und der Selbsteinschätzung des Teilnehmers.
- *M2 - Einfluss auf die Präsentation:* Analyse, ob und wie die präsentierende Person ihr Verhalten während der Präsentation verändert.
- *M3 - Mehrwert für die Kommunikation:* Subjektive Bewertung durch beide Beteiligten, ob das System die Interaktion verbessert.

3.3.4 *Analyse.* Die Auswertung der erhobenen Daten erfolgt in mehreren aufeinander aufbauenden Schritten.

Zunächst wird der zeitliche Verlauf der durch das System erkannten Emotionen analysiert. Dieser Verlauf wird mit der Selbsteinschätzung des Teilnehmers verglichen, um die Genauigkeit der Emotionserkennung zu bewerten. Dazu wird überprüft, inwieweit die vom System erkannten Emotionen mit den vom Teilnehmer angegebenen emotionalen Zuständen übereinstimmen.

Anschließend werden die beiden Versuchsdurchläufe miteinander verglichen. Dabei wird untersucht, ob sich Unterschiede im Verhalten der präsentierenden Person zwischen dem Durchlauf ohne System und dem Durchlauf mit aktivierter Emotionserkennung erkennen lassen. Insbesondere wird analysiert, ob Anpassungen im Präsentationsstil oder in der Reaktion auf den Gesprächspartner auftreten.

Abschließend werden die quantitativen Ergebnisse (Emotionserkennung und Verlauf) und die qualitativen Ergebnisse (subjektive Einschätzungen) zusammengeführt. Auf dieser Grundlage wird beurteilt, ob das System einen erkennbaren Mehrwert für die Gesprächsführung bietet und inwieweit die bereitgestellten Rückmeldungen sinnvoll genutzt werden können.

4 Schlussfolgerungen und Ausblick

Die fortschreitende Digitalisierung zwischenmenschlicher Kommunikation führt dazu, dass Video-Calls in vielen beruflichen und privaten Bereichen selbstverständlich geworden sind. Trotz ihrer hohen praktischen Relevanz gehen virtuelle Gespräche jedoch mit Einschränkungen in der Wahrnehmung nonverbaler und emotionaler Signale einher [3]. Dieses Position Paper ist im Forschungsfeld Künstlicher Intelligenz, des Affective Computing und der Human-Computer-Interaction angesiedelt und befasst sich mit der automatischen Emotionserkennung in Video-Calls.

Um diese Problemstellung zu adressieren, wurde ein prototypischer Ansatz für die Echtzeiterkennung von Emotionen in einem One-to-One-Video-Call vorgeschlagen. Grundlage des Systems ist die Analyse von Gesichtsausdrücken mithilfe Künstlicher Intelligenz. Der Prototyp soll als Webanwendung umgesetzt werden, wobei der Videostream des Gesprächspartners in regelmäßigen Abständen in Einzelbilder zerlegt, serverseitig verarbeitet und hinsichtlich emotionaler Zustände klassifiziert wird. Die Ergebnisse werden anschließend in Echtzeit in einer verständlichen Form an die präsentierende beziehungsweise sprechende Person zurückgemeldet.

Die zentralen Aussagen dieses Papers sind damit erstens, dass Emotionserkennung auf Basis von Gesichtsausdrücken bereits einen gut erforschten technischen Hintergrund besitzt, zweitens, dass bestehende Ansätze jedoch nur begrenzt auf konkrete Video-Call-Szenarien mit direkter Gesprächsunterstützung ausgerichtet sind, und drittens, dass gerade in diesem Anwendungsfeld ein praktischer Mehrwert entstehen kann. Besonders wichtig ist dabei die Reduktion auf einen klar definierten Use Case mit genau zwei Personen, da so die Funktionsweise des Systems kontrolliert untersucht und die Rückmeldungen eindeutig einem Gesprächspartner zugeordnet werden können.

Im weiteren Verlauf der Arbeit wird der vorgeschlagene Prototyp technisch umgesetzt und in einer kontrollierten Versuchssituation evaluiert. Dabei soll untersucht werden, wie präzise die erkannten Emotionen mit der Selbsteinschätzung des Gesprächspartners übereinstimmen und ob die bereitgestellten Hinweise tatsächlich einen Einfluss auf die Gesprächsführung haben. Im Final Paper werden somit die konkrete Implementierung, die Ergebnisse der Evaluation sowie eine kritische Reflexion der Grenzen des Ansatzes dargestellt. Darüber hinaus bietet sich als weiterführende Perspektive an, die Robustheit des Systems unter realistischeren Bedingungen zu verbessern und den Ansatz später auch auf komplexere Meeting-Situationen mit mehreren Teilnehmern auszuweiten.

References

- [1] Amazon Web Services. 2021. *Web Application Hosting in the AWS Cloud: Best Practices*. Technical Report. Amazon Web Services. <https://docs.aws.amazon.com/pdfs/whitepapers/latest/web-application-hosting-best-practices/web-application-hosting-best-practices.pdf>
- [2] G. Fauville, M. Luo, A.C.M. Queiroz, A. Lee, J.N. Bailenson, and J. Hancock. 2023. Video-conferencing usage dynamics and nonverbal mechanisms exacerbate Zoom Fatigue, particularly for women. *Computers in Human Behavior Reports* 10 (2023), 100271. doi:10.1016/j.chbr.2023.100271
- [3] Francesco Galvano. 2023. Nonverbal Cues in Remote Work Environments: Navigating the Dynamics of Communication. <https://www.behavioranalysisiteam.com>. Accessed via PDF document.
- [4] Huilin Ge, Zhiyu Zhu, Yuewei Dai, Biao Wang, and Xuedong Wu. 2022. Facial Expression Recognition Based on Deep Learning. *Computer Methods and Programs in Biomedicine* 215 (2022), 106621. doi:10.1016/j.cmpb.2022.106621
- [5] Zi-Yu Huang, Chia-Chin Chiang, Jian-Hao Chen, Yi-Chian Chen, Hsin-Lung Chung, Yu-Ping Cai, and Hsiu-Chuan Hsu. 2023. A Study on Computer Vision for Facial Emotion Recognition. *Scientific Reports* 13 (2023), 8425. doi:10.1038/s41598-023-35446-4
- [6] Ruchi Jayaswal, Mohd. Aquib Ansari, Manish Dixit, Dushyant Kumar Singh, and Shah Nawaz Ahmad. 2025. Advances in Facial Expression Recognition Technologies for Emotion Analysis. *Discover Computing* 28 (2025), 203. doi:10.1007/s10791-025-09699-8
- [7] Byoung Chul Ko. 2018. A Brief Review of Facial Emotion Recognition Based on Visual Information. *Sensors* 18, 2 (2018), 401. doi:10.3390/s18020401
- [8] Thomas Kopalidis, Vassilios Solachidis, Nicholas Vretos, and Petros Daras. 2024. Advances in Facial Expression Recognition: A Survey of Methods, Benchmarks, Models, and Datasets. *Information* 15, 3 (2024), 135. doi:10.3390/info15030135
- [9] Mohammad Rami Koujan, Luma Alharbawee, Giorgos Giannakakis, Nicolas Pugeault, and Anastasios Roussos. 2020. Real-time Facial Expression Recognition “In The Wild” by Disentangling 3D Expression from Identity. *arXiv preprint arXiv:2005.05509* (2020). arXiv:2005.05509 [cs.CV]
- [10] Wafa Mellouk and Wahida Handouzi. 2020. Facial Emotion Recognition Using Deep Learning: Review and Insights. *Procedia Computer Science* 175 (2020), 689–694. doi:10.1016/j.procs.2020.07.101
- [11] Shervin Minaee and Amirali Abdolrashidi. 2019. Deep-Emotion: Facial Expression Recognition Using Attentional Convolutional Network. *arXiv preprint arXiv:1902.01019* (2019). <https://arxiv.org/abs/1902.01019>
- [12] Muhammad Sajjad, Fath U Min Ullah, Mohib Ullah, Georgia Christodoulou, Faouzi Alaya Cheikh, Mohammad Hijji, Khan Muhammad, and Joel J. P. C. Rodrigues. 2023. A Comprehensive Survey on Deep Facial Expression Recognition: Challenges, Applications, and Future Guidelines. *Alexandria Engineering Journal* 68 (2023), 817–840. doi:10.1016/j.aej.2023.01.017
- [13] Harisu Abdullahi Shehu, Will N. Browne, and Hedwig Eisenbarth. 2025. Emotion Categorization from Facial Expressions: A Review of Datasets, Methods, and Research Directions. *Neurocomputing* 624 (2025), 129367. doi:10.1016/j.neucom.2025.129367
- [14] Xiaohui Tan, Yachun Fan, Mingrui Sun, Meiqi Zhuang, and Fangbing Qu. 2022. An Emotion Index Estimation Based on Facial Action Unit Prediction. *Pattern Recognition Letters* 164 (2022), 183–190. doi:10.1016/j.patrec.2022.11.019